

linear_regression

Masayuki Sakai

yyyy/mm/dd

Contents

1	最小二乗法	1
1.1	実装	2
2	重回帰モデル	3
2.1	実装	4
2.2	考察	4
3	β の分布	5
4	二乗誤差の分布 : Residual sum of squares	6

1 最小二乗法

ここでは、 n 個の対になる観測値、 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$ と $\mathbf{y} = (y_1, y_2, \dots, y_n)^T \in \mathbb{R}^n$ について最小二乗法により線形モデルである

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \varepsilon_i \sim N(0, \sigma^2)$$

のパラメーター β_0, β_1 を求める。

これは、直線から上下の距離 $|y_i - \beta_0 - \beta_1 x_i|$ の二乗和 L を最小にする $\beta = (\beta_0, \beta_1)^T \in \mathbb{R}^2$ を求める時に、 L の偏微分を用いる。まず

$$L := \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

として、これを β_0, β_1 の関数と見てそれぞれの偏微分を求めると

$$\frac{\partial L}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0, \quad \frac{\partial L}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

となる。この連立方程式を解くと

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

を得る. ただし $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$ である. これは, 共変量 x の値が全て同じことを意味しており, そのような変数はなんら情報を持たないためこのケースは実務上無視して良い. また, $\bar{x} = \sum x_i/n, \bar{y} = \sum y_i/n$ である.

ここで, $x' = x - \bar{x}, y' = y - \bar{y}$ とすると, $\bar{y}' = \bar{x}' = 0$ で $\bar{\beta}_0 = 0, \hat{\beta}_1 = \sum x_i y_i / \sum x_i^2$ となり計算が簡単になる. 加減による傾きの影響は無いので, $\hat{\beta}_1$ の推定はこのままで問題はないが, 切片項 β_0 はもとのスケールで計算する必要がある.

1.1 実装

ここでは, シンプルに x, y という2つのベクトルを受け取った場合に, $\hat{\beta}_0, \hat{\beta}_1$ を返す関数を書く.

```
lsm <- function(x, y){
  if(length(unique(x)) == 1){
    stop("x has only 1 unique values")
  }
  # estimation
  bar_x <- mean(x); bar_y <- mean(y)
  hat_b1 <- sum((x-bar_x)*(y-bar_y)) / sum((x-bar_x)^2)
  hat_b0 <- bar_y - hat_b1 * bar_x

  # return
  return(list(b0 = hat_b0, b1 = hat_b1))
}
```

```
set.seed(100)
beta <- c(0.3, 0.8)
n <- 100
x <- c(rep(1,n), rnorm(n)) %>% matrix(nrow=100, byrow=FALSE)
y <- x %*% beta + rnorm(n)

fit <- lsm(x=x[,2], y=y[,1])
fit_centered <- lsm(x=x[,2]-mean(x[,2]), y=y-mean(y))


print(fit)
```

```
## $b0
## [1] 0.3114477
##
## $b1
## [1] 0.6946326
```

```
print(fit_centered)
```

```
## $b0
## [1] 2.193677e-17
##
## $b1
## [1] 0.6946326
```

```
data.frame(x=x[,2], y=y) %>%
  ggplot(aes(x=x, y=y)) +
  geom_point() +
  geom_abline(aes(slope = fit$b1, intercept = fit$b0, color = 'non-centralization'), show.legend = TRUE) +
  geom_abline(aes(slope = fit_centered$b1, intercept = fit_centered$b0, color = 'centralization'), show.legend = TRUE) +
  labs(color="Lines") +
  scale_color_manual(values = c('orange', 'lightblue'))
```



2 重回帰モデル

$$y := \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad X := \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \beta := \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$$

とすると,

$$L = \|y - X\beta\|^2$$

とかけて,

$$\nabla L := \begin{bmatrix} \frac{\partial L}{\partial \beta_0} \\ \frac{\partial L}{\partial \beta_1} \end{bmatrix} = -2X^T(y - X\beta)$$

と表すことができる。ここから共変量の数を増やして

$$X := \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix} \quad \boldsymbol{\beta} := \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

とする。このように拡張してもやることは変わらず、

$$-2X^T(y - X\beta) = \mathbf{0}$$

を解く。結果として、

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

を得る。ただし、 $(X^T X)^{-1}$ は存在するとする。

2.1 実装

```
lsm <- function(X, y){
  res <- solve(t(X)%*%X) %*% t(X) %*% y
  return(res)
}
```

```
n <- 100
p <- 3
set.seed(888); beta <- rnorm(4)
x <- matrix(1, nrow=n, ncol=p+1)
x[, -1] <- rnorm(100*p)
set.seed(666); y <- x %*% beta + rnorm(n)

fit <- lsm(X = x, y = y)
data.frame(beta = beta, fit = fit, diff = beta - fit)
```

```
##          beta          fit          diff
## 1 -1.9513433 -2.0154629  0.064119522
## 2 -1.5443662 -1.5412662 -0.003099945
## 3  0.7298327  0.7150430  0.014789653
## 4 -0.2775818 -0.3555181  0.077936312
```

2.2 考察

2.2.1 $(X^T X)^{-1}$ の存在

次の場合は $(X^T X)^{-1}$ が存在しない。

1. $N < p + 1$
2. X の異なる 2 列が等しい

2.2.2 関連する補題

Lemma 1. 正方行列 $A \in \mathbb{R}^{n \times n}$ について以下は同値である. 1. A が正則 2. $\text{rank}(A) = n$ 3. $\det(A) \neq 0$

Lemma 2. 正方行列 A, B について, 次が成り立つ. 1. $\det(AB) = \det(A)\det(B)$ 2. $\det(A^T) = \det(A)$

Lemma 3. $A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times l}$ として, 以下が成立.

$$\begin{aligned}\text{rank}(AB) &\leq \min\{\text{rank}(A), \text{rank}(B)\} \\ \text{rank}(A^T) &= \text{rank}(A) \leq \min\{m, n\}\end{aligned}$$

Lemma 4. V, W をそれぞれ $\mathbb{R}^n, \mathbb{R}^m$ の部分空間として, 行列 $A \in \mathbb{R}^{m \times n}$ による線形写像 $V \rightarrow W$ の像と核は, それぞれ V, W の部分空間であって, それらの次元の和は n になる. また, その次元は, A の階数に一致する.

2.2.3 実務上の仮定

以降では, $X \in \mathbb{R}^{N \times (p+1)}$ の階数は $p+1$ であることを仮定する. $p=1$ の場合は $\text{rank}(X) = 2 = p+1$ と同値.

3 β の分布

被説明変数 $y \in \mathbb{R}^N$ が共変量 $X \in \mathbb{R}^{N \times (p+1)}$ とその係数 $\beta \in \mathbb{R}^{p+1}$ と誤差項 $\varepsilon \sim N(\mu, \sigma^2 I)$ によって下記のような関係にあると仮定する.

$$y = X\beta + \varepsilon$$

ここで, 前項のように β と推定された $\hat{\beta}$ は異なるものであることに注意しよう. あくまで β の値は未知である. いま, あらためて $\hat{\beta}$ は次のように表せることを確認する.

$$\begin{aligned}\hat{\beta} &= (X^T X)^{-1} X^T y \\ &= (X^T X)^{-1} X^T (X\beta + \varepsilon) \\ &= \beta + (X^T X)^{-1} \varepsilon\end{aligned}$$

となり, $\hat{\beta}$ は ε によって決まることがわかる. ε が従う分布はその平均を $E[\varepsilon] = \mathbf{0}$ と仮定していることから, $\hat{\beta}$ の分布の平均は β となる. このように, ある推定量の平均が真値に一致する時, その推定量を不偏推定量 (unbiased estimator) と呼ぶ. また, $\hat{\beta}$ の分散を考えよう. それぞれの要素の分散 $V(\hat{\beta}_i)$ は定義通り $E(\hat{\beta}_i - \beta_i)^2$ である. また, それぞれの要素間の共分散 $\sigma_{i,j} = \text{Cov}(\hat{\beta}_i, \hat{\beta}_j), (i \neq j)$ と定めれば, $\hat{\beta}$ の共分散行列は, 次のようになる.

$$\begin{aligned}V(\hat{\beta}) &= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T] \\ &= E[(\beta + (X^T X)^{-1} X^T \varepsilon - \beta)(\beta + (X^T X)^{-1} X^T \varepsilon - \beta)^T] \\ &= E[(X^T X)^{-1} X^T \varepsilon \varepsilon^T (X^T X)^{-1} X^T] \\ &= (X^T X)^{-1} E[\varepsilon \varepsilon^T] X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1}\end{aligned}$$

となる. これより $\hat{\beta}$ の分布は下記のようになることがわかった.

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

4 二乗誤差の分布 : Residual sum of squares

ここでは、 $L = \|\mathbf{y} - X\hat{\boldsymbol{\beta}}\|^2$ の分布を導出する．まず $H := X(X^T X)^{-1}X^T$ として、その性質を確認していく．

以下を確認しなさい．

$$\begin{aligned}H^2 &= H \\(I - H)^2 &= I - H \\HX &= X \\\hat{\mathbf{y}} &= H\mathbf{y} \\\mathbf{y} - \hat{\mathbf{y}} &= (I - H)\boldsymbol{\varepsilon}\end{aligned}$$

また、 $H, I - H$ については次の補題が成り立つ．

Lemma 5. $H, I - H$ の固有値は、 $0, 1$ のみであり、 H の固有値 1 と $I - H$ の固有値 0 の固有空間の次元は $p + 1$ 、 H の固有値 0 と $I - H$ の固有値 1 の固有空間の次元は $N - p - 1$ となる．

証明は後述する．

ここで RSS を次のように定義する．

$$\begin{aligned}RSS &:= \|\mathbf{y} - \hat{\mathbf{y}}\| \\&= [(I - H)\boldsymbol{\varepsilon}]^T [(I - H)\boldsymbol{\varepsilon}] \\&= \boldsymbol{\varepsilon}^T (I - H)^2 \boldsymbol{\varepsilon} \\&= \boldsymbol{\varepsilon}^T (I - H) \boldsymbol{\varepsilon}\end{aligned}$$